

Bayesian Flow Networks



Curso: Modelos Generativos Profundos (MDS7203-1)

Integrantes: Arturo Lazcano y Javier Santidrián

Profesor: Felipe Tobar

Auxiliares: Cristóbal Alcázar y Camilo Carvajal Reyes

Ayudante: Joaquín Barceló

Fecha: 12 de Diciembre, 2023

Introducción

- ¿Qué son las Bayesian Flow Networks?

Modelo generativo profundo que usa inferencia Bayesiana junto con distribuciones de ruido.

- ¿Similitudes con el curso?

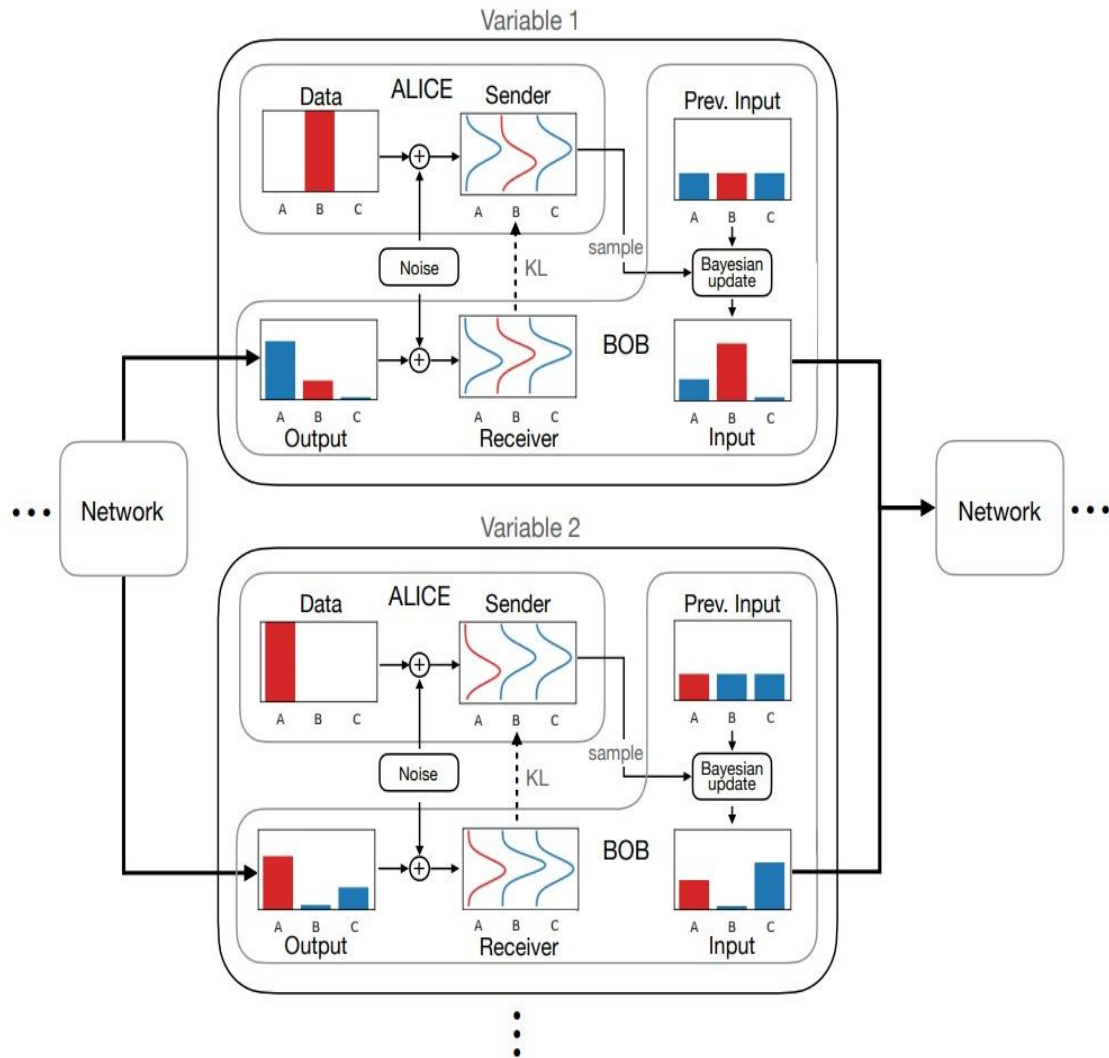
Es un modelo generativo similar a modelos de difusión en el sentido que ambos usan ruido.

- Objetivo del proyecto:

Generación de dígitos, es decir, data discreta (MNIST usual y modificado).

Funcionamiento de BFN

1. Existen 2 sistemas: Alice y Bob.
2. Alice ve la data real mientras que Bob no.
3. Alice y Bob se comunican en cierto instante.
4. Ambos usan una misma distribución de ruido.
5. Bob genera predicciones del modelo.




Algoritmo de Sampling

1. Inicialización de un vector θ uniforme representando incertidumbre sobre K clases.
2. A lo largo de n pasos iterativos los parámetros θ se actualizan exponencialmente basados en muestras normales con ruido controlado, generando la muestra k para el tiempo final de la distribución de salida discreta.

Algorithm 9 Sample Generation for Discrete Data

Require: $\beta(1) \in \mathbb{R}^+$, number of steps $n \in \mathbb{N}$, number of classes $K \in \mathbb{N}$
 $\theta \leftarrow (\frac{1}{K})$
for $i = 1$ to n **do**
 $t \leftarrow \frac{i-1}{n}$
 $\mathbf{k} \sim \text{DISCRETE_OUTPUT_DISTRIBUTION}(\theta, t)$
 $\alpha \leftarrow \beta(1) \left(\frac{2i-1}{n^2} \right)$
 $\mathbf{y} \sim \mathcal{N}(\alpha(K\mathbf{e}_{\mathbf{k}} - \mathbf{1}), \alpha K \mathbf{I})$
 $\theta' \leftarrow e^{\mathbf{y}} \theta$
 $\theta \leftarrow \frac{\theta'}{\sum_k \theta'_k}$
end for
 $\mathbf{k} \sim \text{DISCRETE_OUTPUT_DISTRIBUTION}(\theta, 1)$
Return \mathbf{k}

Datasets



MNIST 28x28 60 mil imágenes de dígitos de una cifra dinámicamente binarizado.




MNIST modificado 64x64 60 mil imágenes de dígitos de dos cifras dinámicamente binarizado.

U-Net para la implementación de la BFN.

Resultados (Sampleo post-entrenamiento)




Sampleo MNIST.




Sampleo MNIST modificado.

Resultados (Evolución de Sampleo)



Procesamiento de imagen en la BFN para MNIST.



Procesamiento de imagen en la BFN para MNIST modificado.

Trabajo a Futuro

- Emplear más tiempo y recursos tanto al entrenamiento de la red como al algoritmo de sampleo de la BFN.
- Probar una red diferente.
- Comparar rendimiento tanto en calidad de imágenes como en tiempo de entrenamiento entre BFN y modelos de difusión.
- Probar otros dataset de imágenes de dígitos más complicadas.

Referencias

- A. Graves, R. K. Srivastava, T. Atkinson, and F. Gomez, “Bayesian Flow networks,” *arXiv preprint arXiv:2308.07037*, 2023.
- S.-H. Sun, “Multi-digit mnist for few-shot learning.”
<https://github.com/shaohua0116/MultiDigitMNIST>, 2019.
- A. Hibble, D. Ghilardi, and A. Turner, “Bayesian flow networks.”
<https://github.com/Algomancer/Bayesian-Flow-Networks>, 2023.

Bayesian Flow Networks



Integrantes: Arturo Lazcano y Javier Santidrián

Profesor: Felipe Tobar

Auxiliares: Cristóbal Alcázar y Camilo Carvajal Reyes

Ayudante: Joaquín Barceló

Fecha: 12 de Diciembre, 2023